

De Novo Molecular Generation : Accélérer la découverte de médicaments par l'IA


Génération, Filtrage et Prédiction de Toxicité de Nouvelles Molécules Drug-like

Hiba Mhada & Wijdane Bassiry • Master DS&BD • FSBM — Université Hassan II

INTRODUCTION

La découverte de médicaments est un processus **lent et coûteux**. L'espace chimique contient 10^{66} molécules potentielles. **Notre solution** : un pipeline complet utilisant **MolMIM** pour générer des candidats à haut score QED, filtrés et validés pour leur non-toxicité, accélérant la recherche thérapeutique de manière significative.


PIPELINE DU SYSTÈME




OBJECTIFS

- Générer des molécules **100% valides** chimiquement.
- Maximiser le score **QED > 0.80** (drug-likeness).
- Prédire la toxicité avec **précision > 97%**.
- Optimiser via algorithme **CMA-ES**.
- Interface **Streamlit + SHAP XAI** pour les chercheurs.

DATA ANALYSIS & FEATURE ENGINEERING



Distributions MW, LogP, QED & SAS — règles de Lipinski




UMAP espace latent — coloré par score QED



Propriétés Physico-chimiques : Les distributions confirment que les molécules respectent les règles de Lipinski — profil *drug-like* optimal.

Diversité Chimique (UMAP) : MolMIM navigue vers des zones de haute qualité thérapeutique sans répliquer l'existant.

Optimisation (Top 12) : Les candidats atteignent un QED de **0.95**, validant l'algorithme **CMA-ES**.



COMPARAISON DES MODÈLES ML



Matrice de confusion — Random Forest


Modèle	Accuracy	AUC-ROC
Random Forest	97.7%	0.991 ★
XGBoost	98.8% ★	0.988

★ Meilleur score par métrique


Interprétation : XGBoost atteint la meilleure accuracy globale (98.8%), tandis que Random Forest excelle sur l'AUC-ROC (0.991).

DASHBOARD EXPERT & AIDE À LA DÉCISION (XAI)


OPTIMISATION STRATÉGIQUE : ANALYSE COUNTERFACTUAL



EXPLICABILITÉ SHAP




REGISTRE & MONITORING



ÉVALUATION VS LITTÉRATURE

Métrique	VAE (Référence)	Notre MolMIM
Validité	97.7%	100% ▲
QED Moyen	0.498	0.823 ▲
Unicité	67.5%	69.4% ▲

Comparaison des Performances de Génération



OUTILS & ENVIRONNEMENT TECHNIQUE

NVIDIA NIM MolMIM Génération	Python Langage	RDKit Chimie	Scikit-Learn IA / ML	XGBoost IA / ML
SHAP XAI	Pandas Analyse	Matplotlib Visualisation	UMAP Réduction dim.	Streamlit Interface
Validation Chimique : Filtrage Lipinski, SA < 4, détection PAINS via RDKit — garantissant 100% de molécules drug-like valides.			Optimisation CMA-ES : Algorithme évolutionnaire guidé dans l'espace latent MolMIM pour maximiser le score QED jusqu'à 0.95.	
Configuration ML - XGBoost : n_estimators=100, learning_rate=0.1 - Random Forest : 100 arbres, Gini impurity - Data Split : Stratified 80/20 pour les classes			Infrastructure & Flux - Compute : Google Colab avec GPU T4 - Communication : API REST via NVIDIA Health - Sérialisation : Joblib pour les modèles	

CONCLUSION

L'intégration du modèle **MolMIM** avec l'optimisation **CMA-ES** et l'IA explicable **SHAP** offre un pipeline transparent et ultra-performant. Les résultats surpassent la littérature avec **100% de validité**, un **QED moyen de 0.823** et un **AUC-ROC de 0.991**, le tout déployé sur une interface Streamlit accessible.

Auteurs : Hiba Mhada & Wijdane Bassiry
Encadrants : M. Ben Lahmer & Mme Guendoul
Institution : FSBM — Université Hassan II, Casablanca
wijdanebassiry3@gmail.com

